
ANÀLISI I SEGMENTACIÓ DE CLIENTS A LA PROVÍNCIA DE BARCELONA A PARTIR DE L'ENQUESTA D'HÀBITS DE CONSUM I COMPRA

PAULA MESTRES GARCIA

Treball Fi de Grau

Tutora: Mercè Farré Cervelló

Febrer 2026

ÍNDEX

1	Introducció	1
1.0.1	Base de Dades: "Enquesta d'hàbits de consum i compra"	1
1.1	Objectius	2
1.2	Metodología	3
I	Marc Teòric	5
2	Marketing	6
2.1	Les Quatre P's del màrqueting	6
2.2	Segmentació de clients	7
2.2.1	Tècniques de segmentació de clients	8
2.2.2	Algoritmes	9
3	Latent Class Analysis	11
3.1	Terminologia i model matemàtic	12
3.2	Estimació dels paràmetres: EM	14
3.3	Ajust i selecció del nombre de classes	15
3.4	Models de Regressió	16
3.4.1	Regressió logística	17
3.4.2	Estimació dels paràmetres (EM)	18
3.5	Avantatges i limitacions	19

II	Marc Pràctic	21
4	Ànalisi i modelització	22
4.1	Tractament de la base de dades	22
4.1.1	Pre-selecció de les variables	23
4.1.2	Selecció de les variables	23
4.2	Procediment d'estimació i anàlisi dels perfils	24
4.2.1	Creació dels models	24
5	Resultats	28
5.0.1	Classes resultants	32
6	Conclusions i discussió	36
6.1	Perfils finals	36
6.1.1	Recomanacions	37
6.2	Futurs estudis	38
III	Bibliografia	40
IV	Àpendix	43
6.3	Recursos Digitals	44
6.4	Ampliació 1: El paquet polCA en R	44
6.4.1	Funcions principals	44
6.4.2	Opcions de la funció polCA()	45
6.4.3	Objecte de sortida	45
6.5	Taules	47

6.6	Gràfics	50
6.6.1	Anàlisi Descriptiu	50
6.6.2	Vabriables segons la classe	55



INTRODUCCIÓ

Avui dia estem avestats a de veure anuncis i campanyes de màrqueting que potser no ens interpel·len, però que trobem a totes bandes. Les empreses inverteixen en les seves campanyes buscant arribar a un gran nombre de possibles clients, però molts cops aquestes no tenen un gran èxit precisament perquè no van dirigides a un públic concret.

En l'àmbit del màrqueting i l'anàlisi de mercats, la segmentació de clients és essencial per a comprendre al comprador i, així, orientar les tècniques comercials cap a les seves preferències i necessitats. Les campanyes ben orientades són una bona inversió que, molt probablement, suposarà un benefici per a l'empresa.

Aquest Treball de Fi de Grau neix de l'interès en aplicar l'estadística al camp del màrqueting. Es busca organitzar als clients segons els seus hàbits de consum, i, tot seguit, identificar diferents *targets* que permetin optimitzar la publicitat i maximitzar les estratègies de venda. L'ús de dades reals extretes de les dades obertes de la Diputació de Barcelona, precisament de l'enquesta sobre hàbits de consum i compra de 2024, proporciona una base sòlida i rellevant per a aquest estudi, a més d'una perspectiva real de la societat.

El principal propòsit d'aquest estudi és separar als consumidors utilitzant les dades disponibles, aplicant LCA, Latent Class Analysis, tècnica adient per les dades del treball i que en l'actualitat està en el punt de mira en el sector de màrqueting. També es pretén estudiar els resultats obtinguts i brindar suggeriments pràctics a empreses o organitzacions que operin a la província de Barcelona per tal que puguin realitzar campanyes enfocades a un target concret que a ells els hi sigui realment d'interès i així puguin aprofitar al màxim els seus recursos.

1.0.1 Base de Dades: "Enquesta d'hàbits de consum i compra"

La Diputació de Barcelona realitza cada 2 anys l'enquesta d'hàbits de consum i compra, on es pretén conèixer els diferents perfils de llars i consumidors, les seves

preferències, els seus hàbits i motivacions de compra. [2]

Les dades seleccionades per fer aquest treball són les de l'enquesta que es va dur a terme els mesos d'abril i juny del 2024, la més recent, on es van obtenir un total de 7.307 respostes de diferents llars familiars principals o primeres residències de Barcelona. A més, es va aplicar un filtre per tal que només aparegui la informació desagregada per als municipis de més de 10.000 habitants. L'enquesta té preguntes centrades en la valoració de l'oferta comercial als municipis i barris, les freqüències de compra, tipologies d'establiments i l'ús d'internet per dur a terme la compra, entre altres.

(Tota aquesta informació plegada obtinguda a partir de l'enquesta ens ajuda a poder crear els diferents perfils i, per tant, ens dona la possibilitat de realitzar una segmentació coherent i realista.)

1.1 OBJECTIUS

L'objectiu principal d'aquest projecte és emprar l'estadística en un context real i pròxim, com Barcelona, amb la finalitat de construir grups d'identitats de clients basades en els seus models d'ús i compra. La idea és que aquests grups vagin més enllà de les característiques demogràfiques dels clients obtenint així un perfil més concret i detallat dels diferents consumidors.

A més, hi ha altres objectius secundaris que es procuren aconseguir per tal que el treball quedi complert i sigui útil en un futur. Aquest objectius són els següents:

- Treballar amb dades obertes de la Diputació de Barcelona per a desenvolupar perfils de clients, analitzant els hàbits de consum dels residents a la província de Barcelona per extreure patrons de comportament.
- Utilitzar metodologies ja cursades, conjuntament amb una nova tècnica de segmentació no vista durant el grau: Anàlisi de classes latents (*Latent Class Analysis*, LCA).
- Avaluar la utilitat i la interpretabilitat dels segments obtinguts per a la seva aplicació en estratègies comercials.
- Desenvolupar visualitzacions clares que facilitin la comprensió dels perfils de consumidors per part de tercers (empreses, institucions, etc.).

1.2 METODOLOGÍA

El procés dut a terme per la realització del treball constà de diverses fases presentades a continuació:

1. Selecció i neteja de les dades:

Les dades proporcionades per la Diputació de Barcelona estan desordenades i, a més, hi ha variables que no resulten rellevants. A priori, es fa una selecció de les variables que generen algun interès i que poden caracteritzar els clients. Posteriorment, es fa la neteja de les dades mirant si hi ha algun individu o variable conte molts NA's i, també, si alguna variable es troba repetida, com era el cas d'unes quantes. El criteri per a seleccionar les variables és principalment mantenir aquelles que puguin ser d'interès, com per exemple la despesa que fan, la seva opinió o aquelles que serveixen per identificar l'individu demogràficament com el municipi o el gènere.

2. Anàlisi descriptiva de les dades:

Abans d'inicialitzar la descriptiva s'imposa que les variables qualitatives, la majoria, siguin factors per tal de facilitar tota l'anàlisi. Per poder entendre bé les dades es fa un estudi descriptiu de les variables que s'han seleccionat per veure el seu comportament i poder analitzar així la mostra. Es procura fer-se o tenir una idea de la forma més concreta possible de quines variables es tenen per a poder veure la seva distribució i s'haurien de reajustar els nivells per tal de equilibrar la distribució d'aquests.

3. Selecció i aplicació tècnica de segmentació:

D'acord amb les dades i una investigació prèvia es selecciona la millor tècnica de segmentació. En aquest cas, la tècnica seleccionada és LCA (Latent Class Analysis) ja que aquesta ajusta bé per el nostre tipus de dades. LCA s'aplica a les dades utilitzant el programa R. En aplicar la tècnica és mira de representar la segmentació per a facilitar la interpretació.

4. Interpretació dels resultats:

Un cop tenim la segmentació, es representen els resultats i s'analitzen. Es realitza una interpretació en profunditat i es mira de proporcionar amb detall tot el que és rellevant per una empresa per tal que puguin fer amb aquesta informació una millor campanya de màrqueting.

Llenguatge de programació: R

R-Studio i R constitueixen un entorn i llenguatge de programació enfocat en l'anàlisi de dades estadístiques. R va ser dissenyat per Ross Ihaka i Robert Gentleman l'any 1993 en Nova Zelanda. R és àmpliament emprat per a desenvolupar programes estadístics i per a anàlisi de dades, i ha esdevingut l'estàndard en què els estadístics desenvolupen nou programari.

El programa proporciona una àmplia varietat de tècniques estadístiques i numèriques, com regressió lineal i no lineals, tests estadístics, anàlisis de sèries temporals, classificació i agrupació (com és el nostre cas), i a més té una gran quantitat de llibreries que fan extensible el seu ús. Aquestes llibreries són creades pels mateixos usuaris, principalment estadístics, que les fan públiques, a través de repositoris com CRAN, per tal que la resta d'usuaris puguin emprar-les.

Finalment, R té una gran capacitat gràfica altament configurable que facilita la visualització de les dades, no només per aquells que tenen coneixement per a entendre-les sinó també per aquells amb un nivell bàsic d'interpretació. Eines com ggplot2 [17] permeten generar visualitzacions clares i efectives per una millor comprensió dels resultats.

Al llarg del treball, R és l'únic llenguatge que s'aplica per tal de dur a terme tant l'anàlisi descriptiva de les dades com la segmentació de clients.

PARTE I

MARC TEÒRIC

MARKETING

El màrqueting és un concepte fonamental per a qualsevol empresa amb l'objectiu de connectar amb el públic i aconseguir objectius comercials. En si, el màrqueting no és més que un procés pel qual una empresa identifica, s'anticipa i satisfà les necessitats del consumidor a través de la creació, promoció i distribució de productes i/o serveis.

El màrqueting ha experimentat molts canvis al llarg de la seva història i ara com ara segueix en transformació per tal d'adaptar-se a la societat i la tecnologia del moment. Amb l'augment de producció al segle XX, les empreses havien de diferenciar-se de les altres fent així que comences la promoció i la publicitat dels seus productes, punt clau en el desenvolupament del qual avui dia entenem com a màrqueting.

A poc a poc aquestes tècniques s'han anat desenvolupant i adaptant als temps actuals. L'explosió dels mitjans de comunicació com la televisió, la ràdio i les xarxes socials han ajudat en la creació d'estratègies per cridar l'atenció dels clients ideals. Avui dia, el màrqueting digital està en el punt de mira de les empreses, ja que engloba diverses eines i tècniques que s'han transformat en pilars per qualsevol estratègia digital. A més, la intel·ligència artificial, com a la majoria dels llocs, ha guanyat un pes important per analitzar grans volums d'informació per identificar oportunitats de mercat i millorar així l'experiència dels clients.

2.1 LES QUATRE P'S DEL MÀRQUETING

Neil Borden, professor a Harvard, va popularitzar als anys 50 la idea del marketing mix, que més tard es coneixeria com les quatre Ps del màrqueting. L'article de Borden [1] de 1964 mostrava com les empreses podien utilitzar la publicitat per connectar amb els consumidors. Posteriorment, E. Jerome McCarthy va refinar aquests conceptes i els va anomenar formalment les "quatre P", popularitzant-los encara més amb el seu llibre Basic Marketing: A Managerial Approach [7].

- **Producte (Product):** Una campanya de màrqueting comença per entendre el producte: qui el necessita, per què i què el fa únic. Definir-lo correctament és fona-

mental per a la distribució, el preu, la promoció i la gestió del seu cicle de vida.

- **Preu (Price):** És la quantitat que els consumidors estan disposats a pagar per un producte. Els professionals de màrqueting han de vincular-lo amb el valor real i percebut del producte, tenint en compte costos, descomptes, preus de la competència i marges comercials. Ajustar el preu pot donar sensació de luxe o d'accessibilitat, i els descomptes poden atreure clients però afectar la percepció de valor.
- **Distribució (Place):** Fa referència a on i com ha d'estar disponible un producte, tant en botigues físiques com en línia, i com es presenta. La decisió de distribució és clau: productes de luxe es mostren en establiments seleccionats per atraure els consumidors més adequats. També inclou col·locar la publicitat en els mitjans que arribin al públic objectiu.
- **Promoció (Promotion):** L'objectiu de la promoció és comunicar als consumidors la necessitat del producte i que el seu preu és adequat. Inclou publicitat, relacions públiques i l'estratègia mediàtica global per introduir el producte. La promoció sovint es combina amb la distribució per arribar al públic objectiu, tant en línia com fora de línia.

Les quatre P ofereixen un marc sobre el qual construir l'estratègia de màrqueting. Encara que és inevitable que alguns factors es superposin, una correcta comprensió dels clients permet reduir aquesta superposició. Per poder analitzar i entendre els comportaments i preferències dels consumidors, és clau realitzar una segmentació prèvia dels clients, de manera que es puguin identificar patrons i grups similars dins la base de dades.

2.2 SEGMENTACIÓ DE CLIENTS

La segmentació de clients consisteix a identificar grups de consumidors que comparteixen característiques similars, diferenciant-los d'altres grups amb perfils diferents. Aquest procés permet a les empreses comprendre millor els seus públics i desenvolupar estratègies més efectives per generar oportunitats, augmentar vendes i millorar la seva posició competitiva. Tot i que segmentar és relativament senzill, obtenir resultats útils i rellevants és més complex, ja que no existeix una tècnica universalment superior: l'elecció depèn de l'enfocament i de la viabilitat pràctica. Sovint, la

solució estadísticament més sofisticada no és aplicable, i una aproximació més simple pot aportar un valor real més alt.

Quant als mètodes de segmentació, aquests pertanyen a l'àmbit de l'aprenentatge estadístic i es divideixen principalment en aprenentatge supervisat i no supervisat. El supervisat, orientat a la classificació, utilitza variables dependents conegudes per entrenar el classificador i després predir nous resultats, mentre que el no supervisat, propi dels mètodes d'agrupació, busca descobrir patrons i grups sense tenir-los definits prèviament. Entre les tècniques no-supervisades més utilitzades hi trobem K-means, el clustering jeràrquic, el clustering basat en models, l'anàlisi factorial i, com en el cas d'aquest treball, LCA. La tria del mètode adequat depèn tant de la mida i estructura de les dades com del tipus de variables disponibles.

2.2.1 Tècniques de segmentació de clients

Analitzar i entendre el client és una part molt important dins del màrqueting i, per tant, dins l'empresa. Al llarg del temps s'han anat desenvolupant diferents tècniques de segmentació de clients per a separar els usuaris i poder posar el focus en aquells que a cada entitat la interessen.

La segmentació de clients o de mercat és un procés de divisió dels usuaris en subgrups de potencials clients que anomenem segments. L'objectiu de la identificació dels perfils és avaluar amb detall el target que poden interessar a l'empresa i concentrar en ells tota l'atenció per tal que tinguin un èxit més gran les campanyes i estratègies que duguin a terme.

Aquestes tècniques de segmentació procuren mirar característiques comunes com necessitats, interessos o estils de vida. Poder crear aquests subgrups ajuda a veure els interessos que tenen els possibles clients i dirigir així l'atenció en allò que els importa. Hi ha diverses formes de portar a terme aquesta segmentació, a continuació presentem les més comunes:

1. **Demogràfica:** La segmentació demogràfica classifica els consumidors segons variables com l'edat, el salari o la mida de la família, assumint que persones amb perfils similars comparteixen interessos i comportaments de compra. Requereix combinar moltes variables i utilitzar tècniques com el clustering o el *Principal Class Analysis* (LCA), fet que implica disposar de mostres grans i bases de dades sofisticades.

2. **Geogràfica:** Aquest tipus de segmentació divideix el mercat segons criteris com el país, la regió, el clima o la densitat de població. En combinar dades geogràfiques amb demogràfiques, permet generar segments petits i precisos, i és especialment útil en màrqueting internacional per adaptar productes i estratègies a cada zona.
3. **Psicogràfica:** La segmentació psicogràfica analitza el comportament intern dels consumidors a partir de les seves activitats, interessos i opinions, oferint una visió profunda de les seves motivacions de compra. És una tècnica habitual per entendre per què i com les persones trien determinats productes o marques en situacions concretes.
4. **Computacional:** La segmentació computacional es basa en el comportament observable dels usuaris, utilitzant variables com el temps d'ús, els beneficis buscats, l'estatus d'usuari o la seva actitud davant el producte. Ajuda les empreses a detectar com és percebut el producte en el mercat i a identificar quins elements són rellevants per a cada segment.

Tal com s'ha pogut observar, aquestes diferents tècniques de segmentació, entre altres, es basen en les variables que s'utilitzen per dur a terme aquestes segmentacions i no són excloents entre si, és a dir, es poden fusionar diferents tècniques. En el nostre cas treballem amb diferents tipus de variables i, per tant, de tècniques.

2.2.2 Algoritmes

Per a dur a terme qualsevol mena de segmentació s'ha d'escollir un mètode estadístic adequat depenen de diferents factors com les dades disponibles, el temps disponible o els recursos. Segons si es desenvolupa un marc teòric previ a la segmentació o no parlem de segmentació a priori o a posteriori.

En cas que existeixi una idea sobre la segmentació del mercat, sabent quina és la variable objectiu, parlem de segmentació a priori, en aquest cas, doncs, un cop tenim la variable escollida recopilem i analitzem les dades normalment a partir de taules creuades, distribucions de freqüències i, de tant en tant, regressió logística. En aquest cas, com tenim clara la variable objectiu no explorem altres oportunitats d'identificar els segments de mercat que podrien ser significatius i, per tant, importants.

Per altra banda, si no hi ha cap assumpció del marc teòric òptim, no tenim una variable objectiu, parlem de segmentació a posteriori. Aquesta té un enfocament diferent

fent que siguin les mateixes dades les que impulsen la segmentació. Habitualment s'utilitza per dades completes amb molts casos i aplica algoritmes sofisticats per identificar els segments.

Alguns dels mètodes de segmentació, tant supervisats com no-supervisats, més comuns són: els algoritmes de clustering (com el k-means), anàlisis de conjunts (com el Random Forest), detecció automàtica d'interaccions amb la Chi-quadrada, anàlisi factorial o de components principals, anàlisis de classes latents, regressió logística, models mixta entre altres.

LATENT CLASS ANALYSIS

El *Latent class analysis*, LCA, una tècnica estadística molt poderosa i útil, ja que permet descobrir segments ocults i no observables dins d'una població. Aquesta és especialment útil en camps on és crucial comprendre l'heterogeneïtat entre individus, com és el cas del màrqueting.

L'objectiu d'aquesta tècnica és dividir un grup heterogeni en subgrups homogenis, anomenats classes latents. Aquests subgrups o classes latents comparteixen característiques, comportaments i preferències. Una classe es caracteritza per "patrons de probabilitat condicionada" que indica la probabilitat que una variable prengui uns valors determinats condicionalment a la classe a la que pertanyen.

Aquest tipus de models van ser proposats per Paul F. Lazarsfeld l'any 1950 sota el nom de "Latent structure analysis" amb l'objectiu d'explicar l'heterogeneïtat no observada en respostes dicotòmiques a enquestes. Més endavant, l'any 1968, Lazarsfeld juntament amb Neil W. Henry va formalitzar aquest enfocament en el llibre *Latent Structure Analysis*. [6]

Abans de seguir amb la LCA, cal aclarir què vol dir variables latents en el món estadístic. Aquestes són variables que no s'observen directament sinó que són inferides, a través d'un model matemàtic, a partir d'altres variables observades directament. Un avantatge que té l'ús de variables latents és que redueix la dimensionalitat de les dades.

El LCA intenta detectar la presència de classes latents, la creació de patrons d'associació de les variables. Igual que en l'anàlisi de factors, mitjançant estimacions de màxima versemblança, el model permet assignar cada individu a la classe que millor el defineix, facilitant-ne la classificació.

Dins de cada classe latent, les variables observades són estadísticament independents. En general, les variables observades són estadísticament dependents. Per tant, l'associació entre les variables observades s'explica a partir de les classes de la variable latent. Aquesta estructura s'acostuma a representar mitjançant taules de classificació

creuada, on cada classe latent defineix una distribució pròpia de freqüències esperades per a les variables observades. La combinació ponderada d'aquestes taules permet aproximar la distribució conjunta observada de les dades.

La tècnica del LCA es caracteritza perquè utilitza una barreja de models probabilístics per a dades categòriques i assumeix independència condicional, ja que dins de cada classe latent les variables observades no estan correlacionades. A més, el nombre de classes latents no és conegut prèviament i s'ha de determinar mitjançant diferents criteris estadístics com l'AIC o el BIC. Finalment, cal destacar que permet incloure variables que expliquen la probabilitat de pertànyer a cada classe.

A diferència de mètodes de segmentació tradicionals com el cluster analysis, que agrupen individus segons distàncies (euclídees o jeràrquiques) intentant minimitzar la variabilitat dins dels grups, LCA utilitza un model probabilístic. Això permet assignar a cada individu una probabilitat de pertinença a cada classe latent, creant segments més flexibles i interpretables per a la presa de decisions en màrqueting.

A més, és especialment adequat per a dades de màrqueting, ja que pot incloure variables de tipus mixte (dicotòmiques, ordinals, contínues) sense necessitat de transformacions complexes [16], i gestiona de manera robusta les dades incompletes [10]. Això facilita l'anàlisi de perfils de consum complexos amb informació parcial.

La classificació probabilística de LCA proporciona una mesura de la incertesa en la pertinença de cada individu a un segment concret. Això és útil en màrqueting, ja que permet crear estratègies dirigides basades en la probabilitat que un client pertanyi a un segment determinat, en lloc d'assumir assignacions rígides.

3.1 TERMINOLOGIA I MODEL MATEMÀTIC

Suposem que observem J variables categòriques politòmiques cadascuna amb K_j resultats possibles, per a individus $i = 1, \dots, N$. Denotem Y_{ijk} els valors observats, de manera que $Y_{ijk} = 1$ si l'individu i dona la resposta k -èsima a la variable j -èsima, i $Y_{ijk} = 0$ altrament.

El model de classes latents aproxima la distribució conjunta observada com una combinació de R taules de classificació creuada, amb pesos p_r (proporcions de mescla), tal que $\sum_{r=1}^R p_r = 1$. Les probabilitats p_r són les probabilitats a priori, sense usar les dades Y . Són ocultes (hidden en cursiva) ja que no es poden estimar directament perquè les dades no estan etiquetades (es desconeix la classe de cada individu). En realitat,

per a cada individu i i cada classe r ,

$$r_i = I_{i \in r}$$

és una v.a. de Bernoulli amb una probabilitat desconeguda igual a p_r a priori i amb un valor que s'anirà estimant iterativament usant les observacions Y_i d'aquest individu en les diferents variables.

Sigui π_{jrk} la probabilitat condicional a la classe que un individu de la classe r respongui l'opció k a la variable j , complint

$$\sum_{k=1}^{K_j} \pi_{jrk} = 1. \quad (3.1)$$

La versemblança d'un patró de respostes Y_i per a un individu de la classe r és

$$f(Y_i; \pi_r) = \prod_{j=1}^J \prod_{k=1}^{K_j} (\pi_{jrk})^{Y_{ijk}}. \quad (3.2)$$

La versemblança total per a cada individu és la suma ponderada

$$P(Y_i | \pi, p) = \sum_{r=1}^R p_r \prod_{j=1}^J \prod_{k=1}^{K_j} (\pi_{jrk})^{Y_{ijk}}. \quad (3.3)$$

La probabilitat posterior de pertinença a la classe r ve donada per la fórmula de Bayes:

$$P(r_i | Y_i) = \frac{p_r f(Y_i; \pi_r)}{\sum_{q=1}^R p_q f(Y_i; \pi_q)}. \quad (3.4)$$

La log-versemblança total de tots els individus i paràmetres és:

$$\ln L = \sum_{i=1}^N \ln \left(\sum_{r=1}^R p_r \prod_{j=1}^J \prod_{k=1}^{K_j} \pi_{jrk}^{Y_{ijk}} \right). \quad (3.5)$$

El nombre de paràmetres estimats és

$$R \sum_j (K_j - 1) + (R - 1). \quad (3.6)$$

Si aquest nombre excedeix el total d'observacions, o bé un menys que el nombre de cel·les de la taula de classificació creuada, el model és no-identificable.

3.2 ESTIMACIÓ DELS PARÀMETRES: EM

El procés intern d'estimació del LCA es duu a terme mitjançant l'algoritme **EM (Expectation–Maximization)** que té com a objectiu trobar els valors dels paràmetres que maximitzen la versemblança de les dades observades. L'algoritme EM (Expectation–Maximization) es un mètode d'aprenentatge no supervisat, per tant, treballa amb dades que no es poden fer servir per fer una estimació directa de la versemblança utilitzant MLE, ja que desconexim les seves etiquetes.

La forma de la log-versemblança (Equació 3.5) és la d'una mixtura finita de distribucions amb etiquetes desconegudes, tractat amb EM [8, 9] per trobar una solució numèrica que maximitzi la versemblança.

Aquest procés es divideix principalment en 2 fases. En la inicialització i dues fases que es van iterant successivament fins la convergència: la fase Esperança (E: expectation) i la fase Maximització (M: maximization). La fase E calcula el valor esperat de les etiquetes dels casos o individus, condicionalment a la distribució inicial o del pas anterior, i la fase M, actualitza els paràmetres utilitzant les probabilitats a posteriori (veure el quadre resum):

Procés pas a pas

1. Inicialització:

- Es fixa un nombre de classes latents R .
- Es donen valors inicials de les probabilitats de classe p_r^0 i de les probabilitats condicionals π_{jrk}^0 , que poden provenir d'una assignació aleatòria o d'una heurística (estimació preliminar basada en coneixement a priori).
- És habitual fer múltiples inicialitzacions per reduir el risc que l'algorisme quedi atrapat en un màxim local de la versemblança.

2. Fase E (Expectation):

- S'estimen les *probabilitats a posteriori* de pertinença de cada individu a cada classe latent, basant-se en els paràmetres actuals.
- Aquesta fase reflecteix la “assignació probabilística” dels individus a les classes latents segons els patrons observats de les variables.

$$P(r_i|y_i, p^o, \pi^o) = E(I \in r) = \frac{p_r^o f(Y_i; \pi_r^o)}{\sum_{q=1}^R p_q^o f(Y_i; \pi_q^o)}. \quad (3.7)$$

3. Fase M (Maximization):

- S'actualitzen els paràmetres p_r i π_{jrk} per maximitzar la versemblança total de les dades, incorporant les assignacions probabilístiques calculades a la fase E.

Els paràmetres s'actualitzen com:

$$\hat{p}_r^n = \frac{1}{N} \sum_{i=1}^N P(r | Y_i), \quad \hat{\pi}_{jrk}^n = \frac{\sum_{i=1}^N Y_{ijk} P(r | Y_i)}{\sum_{i=1}^N P(r | Y_i)}. \quad (3.8)$$

4. Iteració i convergència ($P^o = P^n, \pi^o = \pi^n$):

- Es repeteixen les fases E i M fins que la versemblança total es converteix a un valor estable, és a dir, quan els canvis entre iteracions són molt petits.
- El resultat final és un conjunt de paràmetres que defineixen les probabilitats de cada classe i les probabilitats condicionals de les variables dins de cada classe.

3.3 AJUST I SELECCIÓ DEL NOMBRE DE CLASSES

A vegades el nombre de classes latents es tria per raons teòriques. Sovint l'anàlisi té un caràcter exploratori, amb l'objectiu de trobar el model que s'ajusti millor o que sigui més parsimoniós.

En aquest cas, el procediment pot començar ajustant un model d'independència complet amb $R = 1$ i anar augmentant iterativament el nombre de classes latents fins que s'aconsegueixi un ajust adequat. Tot i que afegir una classe addicional a un model de classes latents millora l'ajust del model existeix el risc d'ajustar-se al soroll i amb un cost d'haver d'estimar $1 + \frac{\sum_j (K_j - 1)}{1 + \sum_j (K_j - 1)}$ paràmetres addicionals.

Els criteris de parsimònia busquen equilibrar el risc de sobreajust i de subajust, penalitzant la log-versemblança amb una funció del nombre de paràmetres estimats. Els criteris clàssics més utilitzats són:

- **BIC** (*Criteri d'informació bayesià, 1978*)

$$\text{BIC} = -2\log(L) + k\log(n) \quad (3.9)$$

on L és la versemblança del model, k el nombre de paràmetres estimats i n el nombre d'observacions.

- **AIC** (*Criteri d'informació d'Akaike, 1973*)

$$\text{AIC} = -2\log(L) + 2k \quad (3.10)$$

on L és la versemblança del model i k el nombre de paràmetres estimats.

Els valors més baixos de tots dos estadístics indiquen un millor ajust del model, a la referència [13] diuen que tenint en compte que el BIC funciona millor en mostres grans, i en cas contrari és recomanable utilitzar tots dues formes de conjunt.

Una altra manera d'avaluar la bondat de l'ajust és mitjançant els estadístics χ^2 de Pearson que compara les freqüències observades q_c amb les freqüències esperades $\tilde{Q}_c$ del model:

$$\chi^2 = \sum_{c=1}^C \frac{(q_c - \tilde{Q}_c)^2}{\tilde{Q}_c}, \quad G^2 = 2 \sum_{c=1}^C q_c \log\left(\frac{q_c}{\tilde{Q}_c}\right) \quad (3.11)$$

on $C = \prod_j K_j$ és el nombre total de cel·les de la taula de contingència.

Els models amb valors més petits de χ^2 o G^2 s'interpreten com a millor ajustats, sempre que no s'estimin un nombre excessiu de paràmetres. Cal tenir en compte que aquests estadístics poden ser poc fiables si moltes cel·les tenen pocs casos observats (Segons la Llei asíptotica, menys de cinc).

3.4 MODELS DE REGRESSIÓ

Els models de regressió amb classes latents generalitzen el model bàsic donant la possibilitat de la inclusió de covariants per predir a quina classe pertany un individu. Aquest mètode estima els coeficients de les covariàncies simultàniament com a part del model de classes latents, és per això que es diu tècnica "one-step".

Les covariàncies s'inclouen en el model de regressió indicant l'efecte en els priors p_r . En aquest tipus de models en comptes d'assumir que tots els individus tenen les

mateixes priors pensarem que cada individu té una prior diferent d'acord amb les covariants observades.

En aquest cas, les fórmules canvien lleugerament, ja que les probabilitats prèvies de pertinença a cada classe (p_{ri}) depenen de les covariables observades de cada individu X_i . Això implica que les priors deixen de ser constants i passen a modelar-se mitjançant una funció logística multinomial:

$$p_{ri} = \frac{e^{X_i \beta_r}}{\sum_{q=1}^R e^{X_i \beta_q}}, \quad r = 1, \dots, R \quad (3.12)$$

on la primera classe s'utilitza com a categoria de referència, de manera que

$$\beta_1 = 0.$$

Per a dur a terme aquests models de regressió fem servir els models de regressió logística.

3.4.1 Regressió logística

La regressió logística s'utilitza quan la variable dependent és dicotòmica. Resulta útil quan es vol modelar la probabilitat d'un esdeveniment a partir d'un conjunt de factors explicatius. Aquest model lineal generalitzat utilitza com a funció d'enllaç la funció *logit*.

Suposem que X_i és el vector de variables explicatives de dimensió k per a l'individu i . Si Y_i és una variable de resposta binària, definim

$$p_i = P(Y_i = 1 | X_i) \quad (3.13)$$

Els logits d'aquestes probabilitats són modelats com una funció lineal de les variables explicatives:

$$\text{logit}(p_i) = \ln\left(\frac{p_i}{1-p_i}\right) = \beta_0 + \beta_1 x_{1,i} + \dots + \beta_k x_{k,i} \quad (3.14)$$

La interpretació dels coeficients β_j en un model de regressió logística és la d'un efecte additiu sobre el *log-odds* del resultat per a una unitat de canvi en la j -èsima variable explicativa.

En el cas que la variable explicativa sigui dicotòmica (per exemple, el gènere), el coeficient β_j representa la diferència en el *log-odds* entre les dues categories. Exponentiant β_j s'obté l'*odds ratio*:

$$\exp(\beta_j) \quad (3.15)$$

que indica com canvien els *odds* de presentar el resultat per a una categoria (en aquest exemple, els homes) en comparació amb la categoria de referència (en aquest cas, les dones).

Existeixen extensions del model per a variables dependents amb més de dues categories. La generalització de la regressió logística per a múltiples categories s'anomena *logit multinomial*. En aquest cas, la funcions de probabilitats venen definides com:

$$\text{logit}(p_i) = \ln\left(\frac{p_i}{p_1}\right), \quad i = 2, \dots, R \quad (3.16)$$

on hi va variant i va variant respecte la classe en la que ens trobem però sempre comparem respecte la primera classe.

3.4.2 Estimació dels paràmetres (EM)

La posterior per a cada individu i i classe r , tenint en compte tant les covariables X_i com les respostes observades Y_i , és:

$$\hat{P}(r_i | X_i, Y_i) = \frac{p_r(X_i; \hat{\beta}) f(Y_i; \hat{\pi}_r)}{\sum_{q=1}^R p_q(X_i; \hat{\beta}) f(Y_i; \hat{\pi}_q)}. \quad (3.17)$$

Les probabilitats de resposta condicionals π_{jr} s'estimen en cada iteració del EM, com passa en el model bàsic, mitjançant l'expressió:

$$\hat{\pi}_{jr} = \frac{\sum_{i=1}^N Y_{ij} \hat{P}(r_i | X_i, Y_i)}{\sum_{i=1}^N \hat{P}(r_i | X_i, Y_i)}, \quad (3.18)$$

on Y_{ij} és el vector d'indicadors de resposta de l'individu i per a la variable observable j , i $\hat{P}(r_i | X_i, Y_i)$ és la probabilitat posterior que l'individu i pertanyi a la classe latent r .

Aquesta expressió permet obtenir les probabilitats estimades $\hat{\pi}_{jr}$ per a cada variable observable i per a cada classe latent, ponderant les respostes observades pel grau d'evidència (posterior) de pertinença a cada classe.

En els models d'*Latent Class Analysis* és habitual considerar més de dues classes latents; per aquest motiu, la parametrització sovint es fa mitjançant una regressió logística multinomial.

Finalment, l'error estàndard dels paràmetres s'obté a partir de la matriu d'informació observada empírica on el vector puntuació per a l'individu i és

$$s(X_i, Y_i; \theta) = \sum_{r=1}^R \theta_{ir} \frac{\partial}{\partial \theta} \left[\ln p_r(X_i; \beta) + \sum_{j=1}^J \sum_{k=1}^{K_j} Y_{ijk} \ln \pi_{jrk} \right], \quad (3.19)$$

$$\text{i } \theta_{ir} = \hat{P}(r_i | X_i, Y_i).$$

Els errors estàndard dels coeficients β s'obtenen com l'arrel quadrada dels valors diagonals de la inversa d'aquesta matriu.

3.5 AVANTATGES I LIMITACIONS

Aquesta tècnica presenta uns avantatges i unes limitacions importants de tenir en compte.

Entre els seus avantatges hi ha la reducció de la dimensionalitat de les dades, la possibilitat d'obtenir una classificació probabilística (no rígida) dels individus i la capacitat d'incorporar covariants que expliquin la pertinença a les classes. Tanmateix, presenta també limitacions: la selecció del nombre òptim de classes no sempre és senzilla, els resultats poden ser sensibles a mostres petites o dades molt desequilibrades, i l'assumpció d'independència condicional dins de les classes pot no complir-se estrictament en totes les aplicacions.

Per a portar a terme aquesta tècnica farem ús de la funció `polCA` del paquet de R anomenat `Polytomous`. Aquesta funció treballa amb variables categòriques i permet estimar models complexos amb covariants.

LCA determina l'estructura de classes que explica la major part de la variància amb el model més simple possible, combinant explicativitat i parsimònia. Aquesta propietat és especialment valuosa en màrqueting, ja que permet obtenir segments sig-

nificatiu sense sobrecarregar el model amb un excés de paràmetres.

PARTE II

MARC PRÀCTIC

ÀNALISI I MODELITZACIÓ

En aquest capítol es presenta el desenvolupament pràctic de l'estudi, basat en la base de dades presentada inicialment, corresponent a l' *Enquesta d'hàbits de consum i compra* elaborada per la Diputació de Barcelona. Aquesta enquesta, realitzada l'any 2024, recull informació detallada sobre els hàbits de compra, les preferències i les motivacions dels consumidors de la província de Barcelona.

El principal propòsit d'aquest estudi és separar els consumidors en grups (segments) usant les dades disponibles, a partir de la generació de models de segmentació amb LCA i altres mètodes multivariants incloent les característiques demogràfiques com a covariants en el model per millorar la segmentació. També es pretén estudiar els resultats obtinguts i brindar suggeriments pràctics a empreses o organitzacions que operin a la província de Barcelona.

A continuació, s'exposa el procés d'anàlisi, que inclou la descripció de les dades, la selecció de variables i la construcció dels models amb el paquet polCA.

4.1 TRACTAMENT DE LA BASE DE DADES

Un cop les dades van estar introduïdes i correctament estructurades a R, es va dur a terme una preselecció de les variables amb les quals es treballaria.

En primer lloc, es van eliminar totes les variables repetides, de manera que només quedés una única variable per pregunta. A continuació, es van avaluar quines variables eren realment rellevants per a l'estudi, ja que la base de dades contenia molta informació que no era necessària per a la segmentació.

L'objectiu principal d'aquesta depuració era reduir la mida de les dades per poder realitzar un estudi més exhaustiu i obtenir uns resultats més precisos i significatius. És per això que, basant-nos en el nostre criteri, es van seleccionar les variables considerades rellevants per a l'anàlisi. Algunes variables, com la freqüència de compra, es van mantenir per la seva rellevància, mentre que altres, com el sexe de les perso-

nes amb les quals conviu l'enquestat, es van descartar per ser irrelevantes per a l'estudi.

4.1.1 Pre-selecció de les variables

Les dades inicials es trobaven en format Excel. Un cop importades al programa R, es van transformar en un `data frame` i es va convertir les variables en factors per poder assignar els noms que venien en un altre full d'Excel als diferents nivells de cada variable. Aquestes etiquetes es trobaven en una altra pestanya del mateix fitxer Excel, de manera que es van associar correctament perquè R les identificués.

4.1.2 Selecció de les variables

Seguidament s'analitzà la presència de valors perduts (NA's) en les 44 variables seleccionades, per tenir apart o eliminar les variables amb un nombre elevat de NA's.




Figura 4.1: Gràfic UpSet dels valors absents a les variables

L'anàlisi dels valors absents mitjançant el gràfic 4.1 mostra que les variables relacionades amb productes ecològics (.Eco) presenten un nombre considerable de valors mancants, especialment en algunes categories com *Ous.Eco_NA*, *Peix.Eco_NA* o *Begudes.Eco_NA*. A més, s'observa una elevada coincidència de valors absents en diverses d'aquestes variables, fet que indica que els valors NA no són aleatoris i, en general, no imputables. Per tant, es van eliminar de l'estudi. La resta de variables tenien les dades completes, quedant-nos amb les 36 variables de la taula 6.1.

Els simples diagrames de barres univariants de les variables categòriques ens permeten detectar nivells amb poca freqüència que vam decidir agrupar, quan tenia

sentit, per aconseguir models amb més parsimònia. Aquesta simplificació permet no només una millor representativitat de cada categoria, sinó que també facilita l'aplicació posterior del model de LCA, reduint la complexitat del càlcul i millorant l'estabilitat dels resultats.

4.2 PROCEDIMENT D'ESTIMACIÓ I ANÀLISI DELS PERFILS

Abans de presentar els resultats finals, cal explicar com s'estimen i com s'analitzen els perfils en aquest estudi. En primer lloc, es construeix el model LCA en base a les variables de resposta de l'enquesta (que anomenem f_1) i, de l'altra, les covariants que descriuen característiques individuals dels participants com el sexe o la comarca (que agrupem a f_0).

Pel que fa a l'anàlisi dels perfils, el treballem des de dues aproximacions complementàries:

1. **Perfils segons les variables de resposta.** Mitjançant regressions logístiques obtenim les probabilitats de pertinença a cada classe en funció dels diferents nivells de cada variable. Això permet descriure com es configuren les classes a partir dels patrons de resposta.
2. **Perfils segons les covariants.** També examinem la relació entre les covariants i la pertinença a les classes estimant els coeficients logístics associats a cada categoria. D'aquesta manera podem analitzar com característiques personals, com el sexe o la comarca, influeixen en la probabilitat d'adscriure's a una classe o una altra.

Conjuntament amb les dues aproximacions podrem caracteritzar el perfil de les classes tant pels patrons com per les dues aproximacions ofereixen una visió completa dels perfils identificats, tant pel que fa als patrons de resposta com a les característiques socials dels participants.

4.2.1 Creació dels models

Per determinar el nombre òptim de classes latents, es van estimar models de classes latents amb i sense covariants utilitzant la funció `poLCA` del paquet R.

Es van definir dues fórmules: una sense covariants,

$$f_0 = \text{cbind}(\text{variables}) \sim 1 \quad (4.1)$$

i una altra que incorpora com a covariables les variables Comarca, Sexe, Edat, N.Estudis, C.Social, Persones.ll i T.Llar,

$$\begin{aligned} \text{cbind}(\text{variables}) \sim & \text{Comarca} + \text{Sexe} + \text{Edat} + \text{N.Estudis} \\ & + \text{C.Social} + \text{Persones.ll} + \text{T.Llar} \end{aligned} \quad (4.2)$$

Es va creure convenient limitar el nombre de classes latents, degut a la mida reduïda de la mostra implica que un nombre elevat de classes podria generar estimacions inestables i poc fiables, ja que cada classe disposaria d'un nombre insuficient d'observacions per a una caracterització robusta. Els models amb un excés de classes tendeixen a capturar soroll propi de les dades en lloc d'estructures latents reals, fet que augmenta el risc de sobreajust i en dificulta la interpretació substantiva. Finalment, limitar el nombre de classes facilita la comparabilitat entre models i garanteix que les solucions obtingudes siguin interpretables i útils des del punt de vista analític. Es va establir un nombre inicial de 4 classes, tenint en compte que a la fórmula 3.6 es va establir un màxim de quatre classes com a criteri raonable i metodològicament justificat.

A partir d'aquestes fórmules, i tenint en compte el nombre màxim de grups que volem, es van ajustar models amb un nombre creixent de classes ($R = 2, 3, 4$), tant sense covariants (Models 1–3) com amb covariants (Models 4–6) que es van comparar. Posteriorment, es van comparar els resultats obtinguts mitjançant diversos criteris d'ajust i parsimònia: el criteri d'informació d'Akaike (AIC), el criteri d'informació bayesià (BIC), la log-versemblança (LogLik) i el test de bondat d'ajust χ^2 (G^2).

Taula 4.1: Comparativa dels models de classes latents amb i sense covariants

Model	nclass	AIC	BIC	LogLik
Model 1	2	313872.4	314789.6	-156803.2
Model 2	3	306657.0	308036.4	-153128.5
Model 3	4	303993.8	305835.2	-153128.9
Model 4	2	313623.6	314747.8	-156648.8
Model 5	3	305053.1	306846.2	-152266.6
Model 6	4	303097.0	305559.1	-151191.5

Segons la Taula 4.1, els models amb covariants (Models 4–6) tenen valors lleugerament inferiors d'AIC i BIC. D'entre tots, el **Model 6** (amb 4 classes latents i covariants) és el que presenta els valors més baixos d'AIC (302820.3) i BIC (305282.4), juntament amb la log-versemblança més alta (LogLik = -151053.1). Cal destacar que aquests valors van canviant cada generació de nous models que fem ja que no hi ha cap llavor fixada, tot i això el millor model sempre coincideix.

Tot i que a priori el model semblava el millor, es van fer diferents estimacions dels models per poder avaluar l'estabilitat i si aquest ens proporcionava informació útil. Així, doncs, en realitzar diferents estimacions els valors obtinguts tant de coeficients com de probabilitat variaven notablement indicant que el model era excessivament inestable. Així que vam idear, de manera heruística, procediments per reduir l'estabilitat i millorar la interpretació de resultats.

Pel que fa a les covariables vam anar mirant els p-valors per cada classe de cada covariable i aquells amb un valor superior a 0.05 els anàvem extraient de manera progressiva i veient com afectava el model. Pel que fa a les variables s'ha anat mirant quines eren les que no ens proporcionaven informació rellevant pel que fa a les probabilitats i al eliminar-les milloraven els valors dels AIC i BIC indicant així que tampoc semblaven afectar a com influenciaven la resta de variables. Finalment, el nostre model quedava de la següent forma:

$$\begin{aligned} \text{cbind(variables)} \sim & \text{Comarca} + \text{Sexe} + \text{Edat} + \text{N. Estudis} \\ & + \text{C. Social} + \text{Persones.ll} + \text{T. Llar} \end{aligned} \quad (4.3)$$

on les variables finals són les indicades a la taula reftab:variables.

Finalment, abans d'extreure com a tals conclusions es va mirar si, tot i que el AIC i el BIC eren millors amb 4 classes, amb 3 classes els resultats eren més interpretables traient així una mica d'eficiència al model però proporcionant uns resultats coherents i més còmodes d'interpretar.

Un cop seleccionat el model òptim, es du a terme una anàlisi exhaustiva amb l'objectiu d'avaluar-ne la interpretabilitat i la rellevància pràctica. Aquesta fase permet determinar si el model, malgrat presentar un bon ajust estadístic, aporta informació realment útil per a la comprensió del fenomen estudiat o si, per contra, seria més adequat considerar una especificació alternativa que resulti més informativa des d'un punt de vista analític. Per a dur-lo a terme vam agafar les variables i vam calcular la desviació típica de cada variable i cada nivell extrem d'aquestes de forma que podem

veure si hi ha molta variabilitat entre aquestes i així determinar si el fet d'estar en una classe o un altre depèn realment de les variables i el nivell en què es troben. El fet de mirar els nivells extrems és perquè aquest solen ser els més discriminants, ja que són valors molt oposats.

RESULTATS

Finalment, es van extreure els resultats obtinguts mitjançant l'aplicació del model LCA sobre les variables de consum i hàbits de la llar. Per garantir la fiabilitat de l'estudi, el model s'ha executat mitjançant un procés iteratiu de 50 repeticions amb diferents valors inicials (seeds), seleccionant finalment la solució amb el menor valor d'AIC, fet que assegura una millor qualitat d'ajust i estabilitat.

Per a la interpretació dels perfils, s'ha seguit un criteri de selecció rigorós basat en la variabilitat inter-classe. S'han prioritzat aquelles variables que presenten una desviació estàndard superior a 0,2 en les seves probabilitats dels nivells dins de cada variable per identificar així les variables discriminants, garantint així que les diferències observades entre grups siguin estadísticament significatives i no fruit de l'atzar. A continuació, es detallen les probabilitats condicionals de les variables seleccionades i el seu pes en la definició de les classes resultants.




Figura 5.1: Gràfic estudi variabilitat a partir de la desviació típica (sd) del nivells de freqüència de compra

Tal com veiem a la Gràfica 5, tot i que les categories de "Cada quinze dies o més" o "No compra" mostren certa dispersió, cap nivell d'aquesta variable arriba al llindar de 0,2. Això implica que la freqüència de compra d'equipament no és un factor determinant per si sol per separar les classes.




Figura 5.2: Gràfic estudi variabilitat a partir de la desviació típica (sd) de les variables amb nivells de puntuació

Mirant les variables de Puntuació i Importància d'Atributs que tenim al model (Gràfic 5) veiem que aquest bloc destaca com el principal de la segmentació, ja que és on trobem les variables amb capacitat discriminant més alta.

Les variables referents a la importància del producte ecològic, de proximitat, la venda directa del productor, el comerç just i l'empaquetatge no només superen la mitjana, sinó que se situen clarament per sobre del llindar crític de 0,2. Aquesta alta variabilitat indica que les respostes estan molt polaritzades entre els grups, sent aquests els atributs que realment defineixen la identitat de cada perfil.

D'altra banda, variables com la valoració de l'oferta o el canal de comunicació superen el llindar moderat de 0,1, aportant matisos rellevants a la interpretació tot i no ser tan determinants.

Finalment, la importància del servei a domicili queda descartada en situar-se gairebé a zero, indicant un consens homogeni en tota la mostra.




Figura 5.3: Gràfic estudi variabilitat a partir de la desviació típica (sd) de la variable d'import global

Pel que fa a les variables de canvi de freqüència per preus o producte (observades en el gràfic 5), totes dues presenten una variabilitat idèntica, situada lleugerament per sobre de 0,10 però sense arribar al llindar de 0,2.




Figura 5.4: Gràfic estudi variabilitat a partir de la desviació típica (sd) del nivells extrems de les diferents variables

L'anàlisi de l'import global de despeses mensuals revela una variabilitat molt baixa, situant-se per sota del 0,05 en totes les seves franges. Això indica que el volum de despesa està distribuït de manera molt homogènia entre els diferents grups identificats. En conseqüència, el nivell de despesa no servirà com a variable diferenciadora, ja que no permet distingir un comportament econòmic particular entre les classes.




Figura 5.5: Gràfic estudi variabilitat a partir de la desviació típica (sd) del nivells de dies de compra

Pel que fa a la preferència temporal de compra revela una variabilitat extremadament baixa en tots els seus nivells. Totes les modalitats, ja sigui la compra de dilluns a dijous, durant el cap de setmana o la indiferència, es situen per sota o molt a prop del llindar de 0,10. Això demostra que no existeixen patrons temporals diferenciats que permetin segmentar la mostra en grups; els hàbits pel que fa a triar el moment de la setmana per comprar productes quotidians o no quotidians són pràcticament transversals a tots els perfils identificats.

En definitiva, l'anàlisi de la variabilitat inter-classe confirma que la segmentació de la mostra respon principalment a criteris de consciència i valors de consum, més que no pas a factors econòmics o d'hàbits de compra rutinaris. Mentre que la despesa mensual i la freqüència de compra presenten una distribució massa homogènia per ser discriminants, les variables d'impacte social i ambiental (producte ecològic, proximitat, comerç just i venda directa) són les veritables variables de classificació.

5.0.1 Classes resultants

A partir dels criteris de variabilitat establerts, s'analitzen les probabilitats condicionals que defineixen el comportament de les tres classes identificades.

A continuació treballem amb les taules de probabilitat de les variables que presenten un nivell que supera el llindar establert de 0.2, tot i això a l'apèndix trobarem totes les taules de probabilitat (6.5).

Per interpretar correctament les taules s'ha de tenir clar que aquestes detallen les probabilitats condicionades a la pertinença de classe per a cadascuna de les variables seleccionades en l'anàlisi de classes latents. Dit d'una altra forma, aquests valors indiquen la probabilitat que un individu té de situar-se en un nivell de resposta determinat segons la classe a la qual ha estat assignat pel model.

Així mateix, s'ha aplicat un codi de colors a les cel·les que presenten la desviació estàndard més elevada, seguint el criteri de variabilitat descrit prèviament a la secció 5.0.1. Aquesta escala cromàtica reflecteix la posició relativa de les probabilitats entre els diferents grups: el color verd indica la probabilitat més alta en comparació amb la resta de classes, el color groc assenyalava una probabilitat de rang intermedi i el rosa identifica la més baixa. En aquells casos on la diferència numèrica entre les probabilitats de dues classes és mínima o poc significativa, s'ha optat per utilitzar el mateix color per a ambdues, emfasitzant així la seva similitud en el comportament condicional.

Suspès	Aprovat	Excel·lent
0.09502959	0.4419230	0.4630474
0.05284138	0.4823340	0.4648247
0.06814956	0.5404607	0.3913898

Taula 5.1: Val.Oferta

Pel que fa a la valoració de l'oferta presentada a la Taula 5.1, s'observa que les classes 1 i 2 mostren una distribució molt similar en la categoria de màxima puntuació, amb probabilitats de 0,4630 i 0,4648 respectivament. En contrast, la classe 3 concentra la seva major probabilitat en el nivell d'aprovat, assolint un valor de 0,5404, mentre que les puntuacions de suspès es mantenen residuals per a tots els grups.

Suspès	Aprovat	Excel·lent	NC
0.17578411	0.2363456	0.4198718	0.167998426
0.01285761	0.1917604	0.7868829	0.008499108
0.11598314	0.7654712	0.1158281	0.002717542

Taula 5.2: Imp.ProdEcologica

Suspès	Aprovat	Excel·lent	NC
0.083454957	0.14253163	0.6776961	0.096317339
0.003631138	0.05386255	0.9407084	0.001797939
0.046518781	0.60099031	0.3488318	0.003659099

Taula 5.3: Imp.ProdProximitat

En l'anàlisi de la importància del producte ecològic detallada a la Taula 6.6, la classe 2 destaca amb una probabilitat de 0,7868 en la categoria d'excel·lent, xifra que contrasta amb el 0,1158 obtingut per la classe 3 en aquest mateix nivell. La classe 3, per la seva banda, situa el seu gruix de probabilitat en la categoria d'aprovat amb un 0,7654, mentre que la classe 1 presenta una distribució més fragmentada entre l'excel·lent (0,4198) i l'aprovat (0,2363).

Quant a la importància de la proximitat dels productes reflectida a la Taula 6.7, els resultats indiquen que la classe 2 té una probabilitat gairebé absoluta d'atorgar una valoració d'excel·lent amb un 0,9407. La classe 1 també mostra una clara tendència cap a l'excel·lència amb un 0,6776, a diferència de la classe 3, que torna a concentrar la seva probabilitat en el nivell d'aprovat amb un 0,6009.

Suspès	Aprovat	Excel·lent	NC
0.093065132	0.10087294	0.6806424	0.125419553
0.001895036	0.06175921	0.9333439	0.003001888
0.056885079	0.62568117	0.3106093	0.006824484

Taula 5.4: Imp.DirecProductor

Suspès	Aprovat	Excel·lent	NC
0.143174825	0.1984872	0.5108407	0.147497367
0.004920835	0.1793795	0.8123553	0.003344352
0.090946861	0.7428084	0.1597451	0.006499645

Taula 5.5: Imp.ProdArtesanal

La importància de la venda directa del productor que es mostra a la Taula 6.8 segueix un patró consistent amb les variables anteriors, on la classe 2 presenta una probabilitat de 0,9333 en el nivell d'excel·lent. La classe 1 manté una probabilitat alta en aquesta categoria (0,6806), mentre que la classe 3 se situa majoritàriament en la franja d'aprovat amb un 0,6256 de probabilitat.

Respecte a la valoració del producte artesanal recollida a la Taula 6.9, la classe 2 lidera novament la categoria d'excel·lent amb un 0,8123. En aquest apartat, la classe 3 assoleix la seva probabilitat més alta en el nivell d'aprovat de tot l'estudi amb un 0,7428, mentre que la classe 1 es reparteix principalment entre l'excel·lent (0,5108) i l'aprovat (0,1984).

Suspès	Aprovat	Excel·lent	NC
0.13039827	0.1941126	0.3857802	0.28970890
0.00927523	0.1776686	0.7956167	0.01743952
0.10290700	0.7096582	0.1622874	0.02514740

Taula 5.6: Imp.ComerçJust

Suspès	Aprovat	Excel·lent	NC
0.117903595	0.1922705	0.5776860	0.112139987
0.008118071	0.1208529	0.8687764	0.002252542
0.068773910	0.6051096	0.3233516	0.002764917

Taula 5.7: Imp.Empaquetatge

L'anàlisi del comerç just presentat a la Taula 6.10 mostra que la classe 2 té una probabilitat de 0,7956 de considerar-lo excel·lent. Per contra, la classe 1 redueix la seva probabilitat en aquest nivell fins al 0,3857, superada per la classe 3 que, tot i centrar-se en l'aprobat amb un 0,7096, presenta una distribució més definida cap a la valoració positiva que la primera classe.

En referència a la importància de l'empaquetatge de la Taula 6.11, la classe 2 assoleix un 0,8687 de probabilitat en la categoria d'excel·lent. La classe 1 mostra un valor moderat de 0,5776 en aquest mateix nivell, mentre que la classe 3 manté el seu comportament característic concentrant un 0,6051 de la seva probabilitat en la categoria d'aprobat.

Suspès	Aprovat	Excel·lent	NC
0.28665092	0.09850025	0.3795023	0.23534654
0.04488482	0.24490661	0.6949249	0.01528363
0.21553208	0.55730287	0.2100110	0.017155410

Taula 5.8: Imp.CanalComunicacio

Suspès	Aprovat	Excel·lent	NC
0.4594900	0.05853228	0.1157328	0.36624494
0.1374884	0.36608464	0.4629238	0.03350323
0.3232398	0.49812860	0.1477566	0.03087505

Taula 5.9: Imp.Plataforma

D'acord amb les dades sobre la importància del canal de comunicació de la Taula 6.12, la classe 2 registra una probabilitat de 0,6949 en la valoració d'excel·lent. En aquest cas, la classe 1 presenta una de les probabilitats de suspès més elevades (0,2866), mentre que la classe 3 manté la seva prevalença en l'aprobat amb un 0,5573.

Per acabar, la importància de la plataforma analitzada a la Taula 6.13 revela que la classe 1 té la seva probabilitat més alta en la categoria de suspès amb un 0,4594. En aquesta variable, tant la classe 2 com la classe 3 desplacen el seu pes cap a la categoria d'aprobat, amb probabilitats de 0,3660 i 0,4981 respectivament, essent l'única variable on la classe 2 no domina clarament el nivell d'excel·lent.

Finalment, es va dur a terme una petita anàlisi per trobar relació amb el sexe i l'edat, ja que solen ser dos factors que afecten bastant els consumidors en l'àmbit global i volíem saber si era així també en aquest cas.

Classe	Home	Dona	No Binari
Classe 1	32.64%	67.35%	0.00%
Classe 2	35.32%	64.62%	0.00 %
Classe 3	44.77%	55.22%	0.00%

Taula 5.10: Distribució per Sexe

Classe	16-29	30-44	45-64	65 i més
Classe 1	0.034 %	2.97%	20.74%	75.93%
Classe 2	4.95%	12.84%	46.67%	35.51%
Classe 3	8.95%	15.02%	40.16%	35.88%

Taula 5.11: Distribució per Edat

L'anàlisi de la composició demogràfica condicionant per classe que podem observar a les Taules 5.11 i 5.10 revela que la Classe 1 és la més envellida i feminitzada, amb un 75,93% d'integrants majors de 65 anys i un 67,39% de dones. La Classe 2, identificada com el segment més conscient, es concentra en la maduresa adulta (47,33% entre 45-64 anys) amb una forta base femenina del 64,63%. Finalment, la Classe 3 presenta l'estructura de gènere més equilibrada (55,23% dones) i una distribució d'edat centrada també en els 45-64 anys (40,14%), consolidant-se com el perfil pragmàtic majoritari del mercat.

CONCLUSIONS I DISCUSSIÓ

Un cop analitzades les dades aquesta secció interpreta els resultats per donar sentit al comportament del consumidor. L'anàlisi de classes latents ha permès segmentar la mostra en tres perfils diferenciats que no es defineixen pel seu volum de despesa, sinó per la seva escala de valors, el seu nivell d'exigència i la seva relació amb l'entorn digital.

A continuació, es descriuen detalladament aquestes categories, posant de manifest la fragmentació actual del mercat. Finalment, es reflexiona sobre les limitacions metodològiques trobades i es proposen noves línies de recerca per a futurs treballs, amb l'objectiu d'evolucionar cap a models més robustos i capturar les noves tendències de consum a la llar.

6.1 PERFILS FINALS

El model ha identificat tres perfils clarament diferenciats pel seu nivell d'implicació amb el producte i el seu comportament digital.

Classe 1: El Perfil Distant o Disconnectat

Aquesta classe es caracteritza per una falta de vinculació emocional o pràctica amb els atributs analitzats. És el grup que presenta una variabilitat més alta en categories d'omissió, destacant especialment en el "NC" de variables com ImportGlobal i Imp.ComerçJust. En variables operatives com Imp.Plataforma i Imp.ServeiDomicili, aquest grup tendeix a puntuar amb un "Suspès" o a mostrar-se indiferent. A més, la variable Freq.EquipamentLlar indica que una part important d'aquest segment directament no participa en certes categories de consum, cosa que els defineix com un grup al marge de les tendències de consum conscient o tecnològic que sí que segueixen les altres dues classes.

Classe 2: El Consumidor Conscient i Exigent (Perfil "Premium")

Aquest grup representa el segment més compromès i amb criteris de selecció més

estRICTES. Es defineix per una valoració d'excel·lència en pràcticament tots els atributs de valor afegit. Les variables Imp.ProdProximitat, Imp.DirecProductor i Imp.ProdArtesanal presenten probabilitats properes al 0,90 en la categoria d'"Excel·lent", indicant que l'origen i la manufactura són pilars fonamentals en la seva decisió de compra. A més, és el grup que més valora la Imp.Plataforma i la Imp.CanalComunicacio, mostrant un perfil digitalment actiu que busca informació detallada. El seu baix percentatge de respostes "NC" suggereix un consumidor informat i amb preferències consolidades.

Classe 3: El Consumidor Pragmàtic o d'Aprovat

Aquest segment mostra un interès notable pels productes diferenciats, però amb un nivell d'exigència o disponibilitat a pagar menor que la classe anterior. La seva resposta característica no és l'excel·lència, sinó l'"Aprovat". Això s'observa clarament en variables com Imp.ProdEcologica i Imp.ComerçJust, on prefereixen una qualitat contrastada però sense la necessitat de la màxima puntuació. Un tret distintiu d'aquest grup és la seva sensibilitat econòmica: tot i no ser la variable més discriminant, presenten una interacció rellevant amb CanviFreq. Preus, suggerint que el seu pragmatisme està lligat a una gestió més ajustada del pressupost mensual.

A escala global, l'estudi revela que la segmentació no es produeix per dades demogràfiques o de despesa total (com veiem en la baixa variabilitat de ImportGlobal), sinó per l'escala de valors i la relació amb el canal de venda. Hi ha una fractura clara entre un consumidor "militant" (Classe 2) i un consumidor funcional (Classe 1), amb un grup intermedi (Classe 3) que actua com a pont i que valora la proximitat i l'artesania però sota criteris més pragmàtics. L'alta variabilitat en les variables d'Importància confirma que el mercat actual està altament fragmentat segons la percepció ètica i logística del producte.

6.1.1 Recomanacions

Les evidències extretes del model d'anàlisi de classes latents permeten traçar un full de ruta estratègic adaptat a la realitat del sector retail, entenent que el consumidor ja no és una unitat homogènia definida pel seu pressupost.

Per al Perfil Distant o Classe 1, les recomanacions han d'abandonar el discurs ètic o digital per centrar-se en la comoditat i la funcionalitat més bàsica. Donada la seva alta probabilitat de suspendre l'ús de plataformes digitals (0,4594) i el seu desinterès pels valors del producte, les estratègies comercials s'han de limitar a facilitar el procés de compra físic i tradicional. En aquest grup, l'èxit de venda dependrà de la immediatesa i

de la reducció de qualsevol barrera logística o tecnològica, entenent que aquest consumidor busca resoldre una necessitat funcional sense cap tipus de vinculació emocional o ideològica amb la marca.

En el cas del segment definit com a Consumidor Conscient o Classe 2, la recomanació principal se centra en la transparència radical i l'excel·lència informativa. Atès que aquest grup presenta probabilitats d'exigència superiors al 0,90 en atributs com la proximitat i la venda directa, les empreses han de certificar l'origen i la manufactura artesanal de cada producte. La seva alta competència digital implica que les campanyes de fidelització han de ser riques en contingut tècnic i ètic, utilitzant les plataformes no només com a punts de venda, sinó com a espais de comunicació de valors.

Finalment, per el perfil de Consumidor Pragmàtic o Classe 3, l'estratègia ha d'orientar-se cap al concepte de pragmatisme ètic. Aquest segment actua com el gran nínxol de mercat que valora la sostenibilitat i el comerç just, però que es mou en nivells d'aprovat funcional per mantenir un equilibri econòmic. Per captar la seva atenció, és necessari oferir productes de proximitat o de producció directa sota formats que optimitzin la relació qualitat-preu, com ara marques blanques amb certificat d'origen o paquets d'estalvi. La seva comunicació ha de ser més directa i centrada en la utilitat pràctica de la seva elecció, valorant que el consum conscient pot ser assequible i quotidià.

6.2 FUTURS ESTUDIS

Atesa la naturalesa d'aquest estudi i les limitacions detectades durant el procés de modelització, es proposen diverses línies de recerca per aprofundir en el coneixement del consumidor:

1. Millora de la robustesa del model i tècniques comparatives L'estabilització del model LCA ha estat un repte metodològic a causa de la dificultat de l'algoritme per assolir el màxim de versemblança amb la mostra disponible. Tot i que s'han realitzat entre 50 i 100 rèpliques per assegurar la convergència, es recomana en un futur validar el model amb una base de dades més extensa. Així mateix, seria d'interès aplicar tècniques alternatives de segmentació, com el Cluster Analysis o mètodes basats en aprenentatge automàtic (Machine Learning), per contrastar la consistència dels perfils obtinguts i explorar noves agrupacions.

2. Reducció del biaix i ampliació geogràfica: Per obtenir una visió més polièdrica de la gestió de la llar, seria ideal que l'enquesta fos resposta per diversos membres de

la mateixa unitat familiar. Això permetria creuar variables com l'edat i el rol dins la llar, ajudant a enfocar millor les estratègies de màrqueting segons qui pren la decisió de compra. D'altra banda, caldria ampliar l'àbast fora de la província de Barcelona, comparant el comportament entre ciutadans de grans nuclis urbans i zones rurals, on l'accés a la producció directa podria canviar dràsticament la percepció de les variables de proximitat.

3. Disseny de preguntes sobre alimentació i entorn digital: S'ha detectat que moltes preguntes actuals no aporten prou informació influent sobre el desig real del consumidor. Es proposa evolucionar cap a qüestionaris menys directes per reduir el "No Contesta" en temes tabú o rutinaris, incorporant variables clau sobre l'entorn digital:

Influència de xarxes socials i compra online: Avaluar com el consum de contingut en plataformes i la facilitat de la compra online d'alimentació (un canal en ple creixement) modifiquen la fidelitat a les marques tradicionals.

Hàbits de planificació: Introduir preguntes sobre l'ús d'eines digitals per a la gestió de la llista de la compra, cosa que podria diferenciar encara més el perfil "Premium" del "Pragmàtic".

4. Anàlisi longitudinal i comparativa temporal: Aquesta enquesta es realitza cada dos anys, fet que obre la porta a una anàlisi longitudinal de gran valor. Un futur treball podria comparar la solidesa d'aquests perfils al llarg de diferents edicions per observar si les classes són estructurals o si evolucionen davant canvis socioeconòmics. Identificar si un segment creix en detriment d'un altre permetria preveure tendències de consum a llarg termini i validar si el comportament "militant" o "funcional" és una característica intrínseca del consumidor o un estat transitori.

PARTE III

BIBLIOGRAFÍA

BIBLIOGRAFIA

- [1] Borden, N. H. (1964). The concept of the marketing mix. *Journal of Advertising Research*, 4(2):2–7. (page 6).
- [2] Diputació de Barcelona (2024). Enquesta d'hàbits de consum i compra. Portal de Dades Obertes. Accedit el: 07-01-2026. (page 2).
- [3] ENAE Business School (2023). El marketing como elemento indispensable en la empresa.
- [4] FasterCapital (2023). Análisis de clases latentes para identificar segmentos de clientes ocultos.
- [5] Investopedia (2024). The four ps of marketing.
- [6] Lazarsfeld, P. F. and Henry, N. W. (1968). *Latent Structure Analysis*. Houghton Mifflin, Boston. (page 11).
- [7] McCarthy, E. J. (1960). *Basic Marketing: A Managerial Approach*. Richard D. Irwin, Homewood, IL. (page 6).
- [8] McLachlan, G. J. and Krishnan, T. (1997). *The EM Algorithm and Extensions*. John Wiley & Sons, New York. (page 14).
- [9] McLachlan, G. J. and Peel, D. (2000). *Finite Mixture Models*. John Wiley & Sons, New York. (page 14).
- [10] Muthén, B. and Shedden, K. (1999). Finite mixture modeling with mixture outcomes using the em algorithm. *Biometrics*, 55(2):463–469. (page 12).
- [11] PeruStat (2023). Técnicas avanzadas de segmentación de mercado.
- [12] PMC (2020). Applications of latent class analysis in health and social sciences. *National Center for Biotechnology Information*.
- [13] Schwarz, G. (1978). Estimating the dimension of a model. *The Annals of Statistics*, 6(2):461–464. (page 16).

- [14] ScienceDirect (2016). Latent class analysis in marketing research. *International Journal of Research in Marketing*.
- [15] SEMrush (2024). Guía completa sobre las 4 p del marketing.
- [16] Vermunt, J. K. and Magidson, J. (2002). Latent class cluster analysis. *Applied latent class analysis*, pages 89–106. (page 12).
- [17] Wickham, H. (2016). *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag New York. (page 4).
- [18] Wikipedia (s.f.a). Análisis de clases latentes.
- [19] Wikipedia (s.f.b). Market segmentation.

PARTE IV

ÀPENDIX

6.3 RECURSOS DIGITALS

Per tal de garantir la transparència i facilitar la replicabilitat de la part pràctica d'aquest treball, s'ha habilitat un repositori públic a la plataforma GitHub on es pot consultar el codi complet i la base de dades utilitzada.

- **Enllaç al repositori:** <https://github.com/paulamestres/TFG>

6.4 AMPLIACIÓ 1: EL PAQUET `poLCA` EN R

El paquet `poLCA` és una eina del llenguatge R per a l'estimació de models de classes latents (*Latent Class Analysis*, LCA) i models de regressió de classes latents per a variables politòmiques.

6.4.1 Funcions principals

El paquet inclou diverses funcions, entre les quals destaquen:

- `poLCA()`: funció principal per estimar models de classes latents i models de regressió de classes latents. Permet especificar el nombre de classes, variables manifestes i covariants.
- `poLCA.reorder()`: reordena les classes latents estimades, ja que la seva numeració és arbitrària i pot variar entre estimacions.
- `poLCA.table()`: genera taules de freqüències o probabilitats esperades segons el model estimat.
- `poLCA.predcell()`: calcula les probabilitats estimades per a combinacions concretes de respostes de les variables manifestes.
- `poLCA.entropy()`: calcula l'entropia del model ajustat, mesura de la concentració o dispersió de les probabilitats estimades.
- `poLCA.posterior()`: retorna les probabilitats posteriors de pertinença a cada classe per observació.
- `poLCA.simdata()`: permet generar dades simulades segons l'estructura d'un model de classes latents.

6.4.2 Opcions de la funció polCA()

La funció principal s'executa amb la comanda:

```
polCA(formula, data, nclass = 2, maxiter = 1000, graphs = FALSE,
tol = 1e-10, na.rm = TRUE, probs.start = NULL, nrep = 1,
verbose = TRUE, calc.se = TRUE)
```

Arguments principals

- `formula`: especifica les variables manifestes (en forma `cbind(Y1, Y2, ...)`), i opcionalment les covariants a la dreta de la tilde.
- `data`: conjunt de dades en format `data.frame`.
- `nclass`: nombre de classes latents (R). Valor per defecte: 2.
- `maxiter`: nombre màxim d'iteracions de l'algoritme EM (per defecte 1000).
- `graphs`: si és `TRUE`, mostra gràficament les probabilitats condicionals estimades.
- `tol`: tolerància per determinar la convergència de la log-versemblança (per defecte 10^{-10}).
- `na.rm`: si `TRUE`, elimina observacions amb valors absents a les variables manifestes.
- `probs.start`: valors inicials per a les probabilitats condicionals. Per defecte `NULL`, i els valors s'inicialitzen aleatòriament.
- `nrep`: nombre de repeticions del model amb valors inicials diferents per evitar màxims locals (per defecte 1).
- `verbose`: si `TRUE`, mostra els resultats a la consola.
- `calc.se`: si `TRUE`, calcula els errors estàndard dels paràmetres estimats.

6.4.3 Objecte de sortida

La funció `polCA()` retorna un objecte amb nombrosos elements.

Arguments principals

- `probs`: llista de matrius amb les probabilitats condicionals estimades $\hat{\pi}_{jrk}$ per a cada variable i classe.
- `P`: proporcions estimades de cada classe ($\hat{p}_r$).
- `posterior`: matriu $N \times R$ amb les probabilitats posteriors de pertinença a cada classe per individu.
- `predclass`: vector amb la classe predita per cada observació (assignació modal).
- `coeff`: coeficients estimats del model de regressió de classes latents, si hi ha covariants.
- `aic`, `bic`: criteris d'Akaike i Bayes per avaluar l'ajust i la parsimònia del model.
- `Chisq`, `Gsq`: estadístics de bondat d'ajust (Chi-quadrat i versemblança).
- `llik`: valor màxim de la log-versemblança.
- `numiter`: nombre d'iteracions fins a la convergència.

6.5 TAULES

Taula 6.1: Variables seleccionades i la seva descripció

Variable	Descripció	Inclusa en el model
Covariants		
Comarca	Comarca de residència del participant	No
Sexe	Sexe del participant (Home/Muller)	Sí
Edat	Edat del participant en anys	Sí
N.Estudis	Nombre d'anys d'estudis o nivell educatiu	Sí
C.Social	Categoria o nivell socioeconòmic	No
Persones.ll	Nombre de persones a la llar	No
T.Llar	Tipus de llar (individual, familiar, etc.)	Sí
Variables explicatives		
Val.Oferta	Valoració general de l'oferta de productes	Sí
Freq.AlimentacioFresca	Freqüència de consum d'aliments frescos	No
Freq.RestaAliments	Freqüència de consum de la resta d'aliments	No
Freq.ProductesQuotidians	Freqüència de consum de productes quotidians	No
Freq.EquipamentPersonal	Freqüència d'adquisició d'equipament personal	No
Freq.EquipamentLlar	Freqüència d'adquisició d'equipament per a la llar	Sí
Dia.Quotidians	Dies dedicats a activitats quotidianes	Sí
Dia.NoQuotidians	Dies dedicats a activitats no quotidianes	Sí
Imp.ProdEcologica	Importància atribuïda als productes ecològics	Sí
Imp.ProdProximitat	Importància dels productes de proximitat	Sí
Imp.DirecProductor	Importància de comprar directament al productor	Sí
Imp.ProdArtesanal	Importància dels productes artesanals	Sí
Imp.ComerçJust	Importància del comerç just	Sí
Imp.Empaquetatge	Importància de l'envasament del producte	Sí
Imp.CanalComunicacio	Importància del canal de comunicació amb el producte	Sí
Imp.Plataforma	Importància de la plataforma de venda	Sí
Imp.ServeiDomicili	Importància del servei a domicili	Sí
VerduresFruita	Quantitat de verdures i fruites consumides	No
Carn	Quantitat de carn consumida	No
OliOlives	Quantitat d'oli d'oliva utilitzat	No
FormatgeLactics	Quantitat de formatge i lactis consumits	No
Begudes	Quantitat de begudes comprades	No
Conserves	Quantitat de productes en conserva consumits	No
Ous	Nombre d'ous comprats	No
Peix	Quantitat de peix consumit	No
ImportGlobal	Import total de la compra	Sí
CanviFreq.Preus	Canvi de la freqüència de compra per preus	No
CanviFreq.ProdMB	Canvi de la freqüència de compra de productes de marca blanca	Sí
Freq.CompOnline	Freqüència de compra online	No

Probabilitats

Suspès	Aprovat	Excel·lent
0.09502959	0.4419230	0.4630474
0.05284138	0.4823340	0.4648247
0.06814956	0.5404607	0.3913898

Taula 6.2: Val.Oferta

+2 Cops per setmana	1 cop a la setmana	Cada 15 dies o més	No compra
0.0006593	0.003915954	0.5717489	0.4236758
0.001906	0.002962467	0.8614907	0.1336404
0.000000	0.002940350	0.8213719	0.1756877

Taula 6.3: Freq.EquipamentLlar

Dilluns a Dijous	Divendres a Diumenge	No fixat
0.2465066	0.2159419	0.5375516
0.3424074	0.2758786	0.3817140
0.3512087	0.2671380	0.3816534

Taula 6.4: Dia.Quotidians

Dilluns a Dijous	Divendres a Diumenge	No fixat	NC
0.1365223	0.1270647	0.5695445	0.16686857
0.1868386	0.3040785	0.4934863	0.01559656
0.1825086	0.3097328	0.4634151	0.04434352

Taula 6.5: Dia.NoQuotidians

Suspès	Aprovat	Excel·lent	NC
0.17578411	0.2363456	0.4198718	0.167998426
0.01285761	0.1917604	0.7868829	0.008499108
0.11598314	0.7654712	0.1158281	0.002717542

Taula 6.6: Imp.ProdEcologica

Suspès	Aprovat	Excel·lent	NC
0.083454957	0.14253163	0.6776961	0.096317339
0.003631138	0.05386255	0.9407084	0.001797939
0.046518781	0.60099031	0.3488318	0.003659099

Taula 6.7: Imp.ProdProximitat

Suspès	Aprovat	Excel·lent	NC
0.093065132	0.10087294	0.6806424	0.125419553
0.001895036	0.06175921	0.9333439	0.003001888
0.056885079	0.62568117	0.3106093	0.006824484

Taula 6.8: Imp.DirecProductor

Suspès	Aprovat	Excel·lent	NC
0.143174825	0.1984872	0.5108407	0.147497367
0.004920835	0.1793795	0.8123553	0.003344352
0.090946861	0.7428084	0.1597451	0.006499645

Taula 6.9: Imp.ProdArtesanal

Suspès	Aprovat	Excel·lent	NC
0.13039827	0.1941126	0.3857802	0.28970890
0.00927523	0.1776686	0.7956167	0.01743952
0.10290700	0.7096582	0.1622874	0.02514740

Taula 6.10: Imp.ComerçJust

Suspès	Aprovat	Excel·lent	NC
0.117903595	0.1922705	0.5776860	0.112139987
0.008118071	0.1208529	0.8687764	0.002252542
0.068773910	0.6051096	0.3233516	0.002764917

Taula 6.11: Imp.Empaquetatge

Suspès	Aprovat	Excel·lent	NC
0.28665092	0.09850025	0.3795023	0.23534654
0.04488482	0.24490661	0.6949249	0.01528363
0.21553208	0.55730287	0.2100110	0.01715410

Taula 6.12: Imp.CanalComunicacio

Suspès	Aprovat	Excel·lent	NC
0.4594900	0.05853228	0.1157328	0.36624494
0.1374884	0.36608464	0.4629238	0.03350323
0.3232398	0.49812860	0.1477566	0.03087505

Taula 6.13: Imp.Plataforma

Suspès	Aprovat	Excel·lent	NC
0.27281568	0.1118585	0.3707513	0.24457450
0.06644413	0.2738613	0.6434670	0.01622753
0.20334964	0.5268730	0.2600840	0.00969334

Taula 6.14: Imp.ServeiDomicili

280€ a 399€	400€ a 599€	menys 280€	més 600€	NS/NC
0.1558370	0.1811950	0.2849985	0.2078414	0.17012808
0.1732886	0.2675227	0.2254807	0.2890479	0.04466012
0.2088373	0.2717273	0.2398887	0.2440323	0.03551439

Taula 6.15: ImportGlobal (al mes)

Sí	No
0.2871857	0.7128143
0.4551576	0.5448424
0.5463036	0.4536964


Taula 6.16: CanviFreq.ProdMB










Sí	No
0.2783116	0.7216884
0.4523193	0.5476807
0.5311877	0.4688123










Taula 6.17: CanviFreq.Preus










6.6 GRÀFICS











6.6.1 Anàlisi Descriptiu











6.6.2 Variables segons la classe

